

Reducción de Rizo de Par en Motores BLDC mediante MPC con Estimación Adaptable de BEMF FCS-M2PC + ADALINE

Alejandro León

Instituto de Ingeniería
Universidad Nacional Autónoma de México

April 24, 2026

Contenido

1. Introducción y Planteamiento
2. Marco Teórico: FCS-M2PC
3. ADALINE: Aprendizaje de BEMF
4. Resultados de Simulación
5. Trabajo Futuro: Control Repetitivo

Contexto: Motores BLDC y el Problema del Rizo de Par

- Motores BLDC: alta eficiencia, bajo mantenimiento, dominantes en EVs y robótica.
- **Problema central:** el rizo de par (*torque ripple*) degrada precisión, genera vibraciones y ruido acústico.
- **Fuentes del rizo:**
 - BEMF no ideal (armónicos 5to, 7mo, 11vo...)
 - Cogging torque (estructura magnética)
 - Dead-time del inversor
 - **Model mismatch en el controlador**




Diagrama circuito equivalente
motor BLDC trifásico

Limitaciones del Control Clásico

Enfoques Convencionales

- **Conmutación Six-Step:** Simple, pero rizo significativo a baja velocidad.
- **FOC (Field-Oriented Control):** Reduce rizo, pero depende de sensores de posición (Hall/Encoder) → costo y confiabilidad.

El Problema del *Model Mismatch*

Incluso el **FCS-MPC** (Finite Control Set – Model Predictive Control) sufre cuando el modelo interno difiere de la planta real:

- La mayoría de esquemas MPC asumen BEMF trapezoidal o senoidal ideal.
- Los armónicos reales de la BEMF no están en el modelo → **predicción errónea** → **rizo residual**.

Hipótesis y Objetivo

Hipótesis


Si la forma de onda de BEMF real del motor (incluyendo armónicos) se aprende de manera **adaptativa en línea** y se integra al modelo predictivo del FCS-M2PC, entonces:

1. La referencia de corriente generada producirá **torque constante**.
2. El rizo de par se reducirá significativamente vs. modelos fijos.
3. El sistema se **auto-calibrará** sin datos offline del motor.

Objetivo General

Desarrollar un esquema de control predictivo de corriente **FCS-M2PC** con estimación adaptativa de BEMF basada en **ADALINE** (Adaptive Linear Neuron), capaz de reducir el rizo de par en motores BLDC en entorno **sensorless**.

Arquitectura Propuesta



- **ADALINE** alimenta tanto la **generación de referencia** como el **modelo de predicción** del M2PC.
- **LMS** actualiza los pesos en cada paso usando el error de estimación.

Modelo del Motor BLDC en $\alpha\beta$

Dinámica eléctrica en el marco estacionario de Clarke:

$$\frac{d}{dt} \begin{bmatrix} i_\alpha \\ i_\beta \end{bmatrix} = \frac{1}{L} \left(\begin{bmatrix} u_\alpha \\ u_\beta \end{bmatrix} - R \begin{bmatrix} i_\alpha \\ i_\beta \end{bmatrix} - \begin{bmatrix} e_\alpha(\theta_e) \\ e_\beta(\theta_e) \end{bmatrix} \right) \quad (1)$$

donde la BEMF depende de la forma de onda **shape** $\mathbf{s}(\theta_e)$:

$$\mathbf{e}_{\alpha\beta}(\theta_e) = K_e \cdot \omega_m \cdot \mathbf{s}(\theta_e) \quad (2)$$

- Si $\mathbf{s}(\theta_e) = [\sin \theta_e, -\cos \theta_e]^T \rightarrow$ motor senoidal ideal
- Motor real: $\mathbf{s}(\theta_e)$ contiene armónicos 5to, 7mo, 11vo...
- **El conocimiento preciso de $\mathbf{s}(\theta_e)$ es clave** para generar referencias de corriente que produzcan torque constante.

FCS-M2PC: Control Predictivo con Dos Vectores por Período

Idea clave (Coronado-Andrade et al., 2025): dividir T_s en sub-intervalos y aplicar **combinaciones** de dos vectores activos + vector nulo.

Predicción de corriente al fin del período:

$$\mathbf{i}(k+1) = \mathbf{i}(k) + \mathbf{f}_1 t_1 + \mathbf{f}_2 t_2 + \mathbf{f}_0 t_0 \quad (3)$$

donde $\mathbf{f}_j = \frac{1}{L}(\mathbf{u}_j - \mathbf{e} - R\mathbf{i})$ y $t_1 + t_2 + t_0 = T_s$.

Función de costo:

$$g^* = \min_{t_1, t_2} \|\mathbf{i}_{\text{ref}}^*(k+1) - \mathbf{i}_{\text{pred}}(k+1)\|^2 \quad (4)$$

Ventaja vs. FCS-MPC clásico: reducción de 75–80% en RMSE de corriente (?).




Diagrama vectores de voltaje

¿Por Qué la BEMF Importa Tanto en el M2PC?

La BEMF aparece en **dos lugares críticos**:

1. Generación de $\mathbf{i}_{\text{ref}}^*$

Para torque constante T_{ref} :

$$\mathbf{i}^* = \frac{T_{\text{ref}}}{K_t \|\mathbf{s}\|^2} \cdot \mathbf{s}(\theta_e) \quad (5)$$

Si $\mathbf{s}$ es incorrecto $\rightarrow$ la referencia tiene armónicos $\rightarrow$ torque oscila.

2. Modelo de predicción

$$\mathbf{i}_{\text{pred}} = \mathbf{i} + \frac{T_s}{L}(\mathbf{u} - \hat{\mathbf{e}} - R\mathbf{i}) \quad (6)$$

Si $\hat{\mathbf{e}} \neq \mathbf{e}_{\text{real}} \rightarrow$ predicción sesgada $\rightarrow$ vector de voltaje subóptimo.

Conclusión: Un modelo preciso de $\mathbf{s}(\theta_e)$ mejora *simultáneamente* la referencia y la predicción.

$\rightarrow$ Motivación para aprender $\mathbf{s}(\theta_e)$ del motor real.

ADALINE: Adaptive Linear Neuron (Widrow-Hoff, 1960)

Red neuronal de **una sola capa, sin no-linealidad**, con base de entrada de Fourier:

$$\hat{s}_\alpha(\theta) = \mathbf{w}_\alpha^T \mathbf{x}(\theta) = \sum_{n=1}^H [w_n^c \cos(n\theta) + w_n^s \sin(n\theta)] \quad (7)$$

donde el vector de regresores es:

$$\mathbf{x}(\theta) = [\cos \theta \quad \sin \theta \quad \cos 2\theta \quad \sin 2\theta \quad \cdots \quad \cos H\theta \quad \sin H\theta]^T \in \mathbb{R}^{2H} \quad (8)$$

- Con $H = 10$ armónicos: **40 parámetros totales** (20 por eje α, β).
- Los pesos w_n^c, w_n^s **son los coeficientes de Fourier** de la BEMF.
- Interpretación física directa: $|w_5|$ = amplitud del 5to armónico.

¿Por Qué ADALINE y No una Red Neuronal Profunda?

Red Profunda (BEMFNet)

- 4 capas ocultas (64–128 neuronas)
- $\sim 25,000$ parámetros
- Entrenamiento: 300 epochs, ~ 30 s
- Backpropagation: $O(N_{\text{params}})$ por paso
- Mínimo local (no convexo)
- Pesos: caja negra

ADALINE + Fourier

- 1 capa, sin activación
- **40 parámetros**
- Entrenamiento: pseudoinversa, ~ 12 ms
- LMS online: $O(2H)$ por paso
- **Óptimo global** (problema convexo)
- Pesos = espectro de Fourier


La BEMF es una **función periódica** de $\theta \rightarrow$ la serie de Fourier es su representación **natural y óptima**.

Usar una NN profunda para esto es *usar un aproximador universal cuando existe la solución exacta*.


Fase 0: Entrenamiento Offline (Pseudoinversa)

Dado el dataset $\{(\theta_k, s_{\alpha,k}, s_{\beta,k})\}_{k=1}^N$, construimos:

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}(\theta_1)^T \\ \vdots \\ \mathbf{x}(\theta_N)^T \end{bmatrix} \in \mathbb{R}^{N \times 2H}, \quad \mathbf{W}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{S} = \mathbf{X}^\dagger \mathbf{S} \quad (9)$$



Coefficientes de fourier por armónico



ADALINE vs NN

Fase 1: Aprendizaje Online con LMS

Ley de actualización (Least Mean Squares):

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mu \cdot \underbrace{\left[s_{\text{obs}}(k) - \mathbf{w}^T(k) \mathbf{x}(\theta_k) \right]}_{\text{error de estimación } \epsilon(k)} \cdot \mathbf{x}(\theta_k) \quad (10)$$

Propiedades clave:

- **Convergencia:** $0 < \mu < 4$ (base ortogonal $\rightarrow \lambda_{\max} = 1/2$)
- **Velocidad:** $\tau \approx 1/\mu$ pasos $\approx 1\text{--}2$ rev eléctricas
- **Misadjustment:** $M \approx \mu H$ (residuo en régimen permanente)
- **Costo:** 1 producto punto por paso ($\sim$ microsegundos en DSP)


¿Qué significa esto?

- El motor se **auto-calibra** en ~ 50 ms
- No necesita datos previos del fabricante
- Se adapta a cambios térmicos, envejecimiento, tolerancias de fabricación
- **Implementable en DSP** (TMS320F28xxx) sin modificaciones de hardware

¿Por Qué ADALINE es Idóneo para Este Problema?

Tres razones estructurales (no cosméticas):

1. **La BEMF es periódica en θ** $\rightarrow$ la serie de Fourier es completa y ortogonal para funciones periódicas. No hay pérdida de generalidad al truncar a H armónicos si la energía espectral por encima de H es despreciable.
2. **La base $\{\cos n\theta, \sin n\theta\}$ tiene $\|\mathbf{x}\|^2 = H$ constante** $\rightarrow$ todos los modos convergen a la misma velocidad (no hay *eigenvalue spread*). El LMS es **óptimamente condicionado** para esta base.
3. **Los pesos son directamente los coeficientes de Fourier** $\rightarrow$ se puede inspeccionar *qué armónicos tiene el motor* mirando $|w_n|$. Además, estos pesos son la **inicialización natural** para un controlador repetitivo que necesita conocer el espectro del disturbio.



Configuración de Simulación

Parámetro	Valor
Motor	BLY-344S-240V
R	$1.2 \, \Omega$
L	$2.05 \, \text{mH}$
K_e	$0.404 \, \text{V}\cdot\text{s}/\text{rad}$
K_t	$0.660 \, \text{Nm}/\text{A}$
Polos	4
J	$2.79 \times 10^{-4} \, \text{kg}\cdot\text{m}^2$
V_{DC}	240 V

Control	Valor
T_s	$50 \, \mu\text{s}$ (20 kHz)
ρ (divisiones M2PC)	10
PI: K_p/K_i	0.5 / 50
ω_{ref}	80 rad/s
T_{load}	0.5 Nm
Escalón carga	+1.0 Nm @ 150 ms
ADALINE: H	10 armónicos
LMS: μ	5×10^{-3}

6 métodos comparados: TRAP, SIN, LEARNED (NN profunda), ADALINE offline, ADALINE online desde TRAP, ADALINE online desde SIN.


Resultados: Comparación de 6 Métodos

Método	Ripple [%]	ω P-P [rad/s]	Params
TRAP (baseline)	4.20	0.399	—
SIN	3.77	0.230	—
LEARNED (NN)	3.65	0.243	$\sim 25k$
ADALINE offline	3.65	0.243	40
ADALINE on (TRAP)	3.90	0.201	40
ADALINE on (SIN)	3.81	0.202	40

Hallazgos clave:

- ADALINE offline $\approx$ NN profunda ($\Delta = 0.04\%$) con **625X menos parámetros**.
- ADALINE online converge al nivel del offline: ✓ desde TRAP, ✓ desde SIN.
- **Reducción de ripple vs. TRAP: $\sim 9\%$** — el motor se auto-calibra.





Respuesta Temporal: Torque y velocidad



FCS-M2PC con 6 BEMF y vs Load step

Respuesta Temporal: Torque y Velocidad



Estado Estable: 6 Modelos de BEMF



Zoom SS y Barras ripple

Convergencia del ADALINE Online

Fase 1: Convergencia del ADALINE Online



Coefficientes de fourier por armónico


Extensión: Análisis de Límites a Baja Velocidad

Problema identificado: el observador de BEMF falla cuando $\omega \rightarrow 0$, ya que $\mathbf{e} = K_e \omega \mathbf{s}(\theta) \rightarrow \mathbf{0}$ y la señal se hunde en el ruido del ADC ($\sigma \approx 50 \text{ mA}$, 12-bit).

Se caracterizó en simulación:

- Resolución del encoder vs. velocidad: por debajo de $\sim 15 \text{ rpm}$ el encoder queda “congelado” entre muestras $\rightarrow$ el observador debe interpolar.
- Ripple baseline del M2PC a $\{5, 10, 20, 60\} \text{ rpm}$ con encoder ideal (velocidad impuesta, sin PI).

Conclusión: el rizo crece sustancialmente a baja velocidad $\rightarrow$ motiva extender el controlador para este régimen.



Ripple de par vs. velocidad — M2PC con encoder 2048 PPR

¿Qué Falta? Fuentes de Rizo que ADALINE No Elimina

El ADALINE corrige el *model mismatch* de BEMF, pero quedan fuentes de rizo **que no son error de BEMF**:

Fuentes residuales

- **Cogging torque:** función de θ , independiente de corriente. Armónicos 6to, 12vo.
- **Dead-time del inversor:** distorsiona el voltaje aplicado. Armónicos 5to/7mo.
- **Discretización M2PC:** ρ finito $\rightarrow$ error de cuantización.

Propiedad común

Todas son **perturbaciones periódicas** con frecuencias múltiplos de la frecuencia eléctrica.

$\rightarrow$ Candidatas perfectas para **Control Repetitivo (RC)**.

Control Repetitivo: Rechazo de Disturbios Periódicos

Principio del Modelo Interno: para rechazar una perturbación periódica de período T , el controlador debe contener el generador de señal periódica:

$$C_{RC}(z) = \frac{Q(z) z^{-N}}{1 - Q(z) z^{-N}} \cdot z^P \cdot G_f(z), \quad N = T/T_s \quad (11)$$

Esto provee **ganancia infinita en todos los armónicos** simultáneamente.


Arquitectura propuesta:

1. **ADALINE** (feedforward): corrige errores de BEMF $\rightarrow$ elimina rizo grueso.
2. **RC** (feedback): compensa rizo residual periódico $\rightarrow$ elimina cogging, dead-time.

Conexión ADALINE $\rightarrow$ RC:

- Los pesos del ADALINE revelan el **espectro del motor**.
- Esto informa el diseño de $Q(z)$ y $G_f(z)$ del RC.
- Esquema RC selectivo: atacar solo los armónicos que ADALINE no puede eliminar.

Roadmap de la Investigación



Contribución principal: Arquitectura en tres capas (ADALINE offline → ADALINE online → RC) que ataca el rizo de par desde la causa (BEMF) hasta el efecto residual (perturbaciones periódicas), con complejidad computacional compatible con DSP en tiempo real.

Conclusiones Parciales

1. El **ADALINE con base de Fourier** iguala la precisión de una NN profunda ($\sim 25k$ params) con solo **40 parámetros**, entrenado en **12 ms** vs. 30 s.
2. El **ADALINE online (LMS)** converge en < 2 revoluciones eléctricas y alcanza el mismo rendimiento que el entrenamiento offline, demostrando capacidad de **auto-calibración**.
3. La integración ADALINE + FCS-M2PC reduce el rizo de par en $\sim 9\%$ respecto al modelo trapezoidal convencional, sin requerir datos previos del motor.
4. Los coeficientes de Fourier del ADALINE proveen una **representación interpretable** del motor que sirve como puente natural hacia el **Control Repetitivo**.

Siguiente paso: Integrar RC plug-in para atacar cogging torque y dead-time — las fuentes de rizo que el ADALINE no puede eliminar por diseño.

Referencias
