



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO
PROGRAMA DE MAESTRÍA Y DOCTORADO EN INGENIERÍA
INGENIERÍA ELÉCTRICA - CONTROL

[TÍTULO DE LA TESIS]

TESIS
QUE PARA OPTAR POR EL GRADO DE:
MAESTRO EN INGENIERÍA

PRESENTA:
JOSÉ ALEJANDRO LEÓN SÁNCHEZ

SUPERVISOR:
DR. LUIS ÁLVAREZ-ICAZA LONGORIA
INSTITUTO DE INGENIERÍA, UNAM

MÉXICO, CIUDAD DE MÉXICO, [MES], [AÑO]

JURADO ASIGNADO:

Presidente: Dr. [Nombre]

Secretario: Dr. [Nombre]

1er. Vocal: Dr. [Nombre]

2o. Vocal: Dr. [Nombre]

3er. Vocal: Dr. [Nombre]

La tesis se realizó en el Posgrado de Ingeniería, UNAM.

SUPERVISOR DE TESIS:

Dr. Luis Álvarez-Icaza Longoria

FIRMA

Agradecimientos

[Dedicatoria].

[Agradecimiento institucional].

[Agradecimiento al financiamiento / proyecto].

Acknowledgment

[Acknowledgment in English].

Resumen

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Abstract

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Índice general

Lista de Figuras	X
Lista de Siglas	XI
Notación	XII
1. Introducción	1
1.1. Motivación	1
1.2. Estado del arte	1
1.3. Contribución	2
1.4. Estructura de la tesis	2
2. Preliminares	3
2.1. El motor BLDC y el origen del rizo de par	3
2.2. Modelo eléctrico-mecánico en el marco abc	4
2.3. Transformada de Clarke	5
2.4. El inversor trifásico y sus vectores admisibles	6
2.5. Control predictivo basado en modelo	6
2.6. ADALINE y el algoritmo LMS	7
2.7. Series de Fourier truncadas como base para señales periódicas	8
3. Modelo y planteamiento del problema	10

3.1. Modelo del motor en el marco $\alpha\beta$	10
3.2. Generación de la referencia de corriente	11
3.3. El rizo de par como <i>model mismatch</i>	12
3.4. Planteamiento del problema	13
3.5. Hipótesis	13
3.6. Objetivos	14
4. Control FCS-M2PC con estimación adaptable de la BEMF	15
4.1. Derivación del FCS-M2PC	15
4.1.1. Conjunto reducido de vectores admisibles	15
4.1.2. Reparto del periodo y modelo de predicción	16
4.1.3. Combinaciones, función de costo y selección	17
4.2. ADALINE con base de Fourier para la BEMF	18
4.3. Entrenamiento offline por mínimos cuadrados	19
4.4. Aprendizaje en línea con LMS	20
4.5. Por qué un ADALINE y no una red neuronal profunda	21
4.6. Observador de BEMF en lazo cerrado	22
4.7. Arquitectura integrada	23
5. Caso de estudio y validación numérica	24
5.1. Configuración del caso de estudio	24
5.2. Comparación con supervisión ideal	26
5.3. Convergencia del aprendizaje en línea	28
5.4. Aprendizaje con observador en lazo cerrado	29
5.5. Discusión	30
6. Conclusiones	33
6.1. Conclusiones	33

6.2. Trabajo futuro	33
-------------------------------	----

Bibliografia	35
---------------------	-----------

Índice de figuras

4.1. Sectores del plano $\alpha\beta$ y conjunto reducido de vectores admisibles por sector. El sector vigente (sombreado) determina los dos vectores activos adyacentes que, junto con el nulo, forman $\mathcal{U}(\theta_e)$	16
4.2. Operación del FCS-M2PC: el reparto de T_s entre dos vectores activos ($\mathbf{u}_a$, $\mathbf{u}_b$) y el nulo ($\mathbf{u}_0$) acerca la corriente a la referencia con un escalón mucho menor que el del FCS clásico, que aplica un solo vector durante todo el periodo.	17
4.3. Estructura del ADALINE con regresor de Fourier para la estimación de $\mathbf{s}(\theta_e)$. La posición θ_e genera el regresor $\mathbf{x}(\theta_e)$; dos combinadores lineales con pesos $\mathbf{w}_\alpha$, $\mathbf{w}_\beta$ producen $\hat{s}_\alpha$, $\hat{s}_\beta$. No hay capas ocultas ni funciones de activación: la salida es lineal en los pesos.	19
4.4. Observador discreto de BEMF que provee la señal de aprendizaje al ADALINE. La ganancia $\mathbf{L}_o$ corrige el modelo con el error de corriente $\mathbf{i} - \hat{\mathbf{i}}$; la BEMF estimada $\hat{\mathbf{e}}_{\alpha\beta}$ se normaliza por $K_e\omega_m$ para recuperar la muestra de forma de onda $\mathbf{s}_{\text{med}}$	22
4.5. Arquitectura integrada del FCS-M2PC con estimación adaptable de BEMF. La estimación $\hat{\mathbf{s}}$ del ADALINE (en naranja) se inyecta a la vez en la generación de la referencia y en la predicción del FCS-M2PC: los dos puntos donde el error de modelo de BEMF se convertía en rizo de par.	23
5.1. Corrida completa de los seis métodos con supervisión ideal: velocidad, salida del PI, par electromagnético y magnitud de corriente. El escalón de carga de 0,5 a 1,5 N·m entra en $t = 150$ ms. En las variables lentas los métodos son indistinguibles; las diferencias aparecen en la escala fina del par y de la salida del PI, donde TRAP y SIN oscilan visiblemente.	26

5.2. Régimen permanente con supervisión ideal. Arriba: par y velocidad sobre dos revoluciones eléctricas; TRAP y SIN exhiben la pulsación periódica que los métodos con forma de onda aprendida no tienen. Abajo: rizo de par y rizo de velocidad pico a pico por método.	27
5.3. Convergencia del ADALINE en línea con supervisión ideal. Izquierda: error relativo de pesos $\ \mathbf{W} - \mathbf{W}^*\ _F / \ \mathbf{W}^*\ _F$ para las dos inicializaciones; ambas cruzan el 5 % en 25–35 ms. Derecha: rizo de par instantáneo (ventana móvil de una revolución eléctrica); tras la convergencia, los métodos en línea se asientan en el nivel de los métodos con caracterización previa. El pico en $t = 150$ ms lo produce el escalón de carga en todos los métodos por igual.	28
5.4. Convergencia del ADALINE en línea con observador. La señal de aprendizaje ruidosa vuelve el transitorio errático y más lento que en la figura 5.3: la inicialización senoidal cruza el 5 % hacia los 50 ms y la trapezoidal hacia los 120 ms. En régimen permanente ambas fluctúan por debajo del 5 % sin divergir.	30
5.5. Seguimiento de corriente en $\alpha\beta$ durante los últimos 100 ms del escenario con observador (referencia en línea discontinua). Las referencias de los métodos con forma de onda aprendida son no senoidales: contienen los armónicos que (3.6) exige para sostener un par constante con la BEMF real del motor.	31

Notación

Símbolo	Nota	Significado
$\mathbb{R}$	–	Conjunto de números reales.
$\mathbb{R}^n$	$n \in \mathbb{N}$	Espacio real euclidiano de dimensión n .
$\mathbb{R}^{n \times m}$	$n, m \in \mathbb{N}$	Espacio de matrices reales de n renglones y m columnas.
A^T	$A \in \mathbb{R}^{n \times m}$	Matriz transpuesta de A .
$A^\dagger$	$A \in \mathbb{R}^{n \times m}$	Pseudoinversa de Moore–Penrose de A .
$\mathbb{I}_n$	–	Matriz identidad de dimensión $n \times n$.
$\ \mathbf{v}\ $	$\mathbf{v} \in \mathbb{R}^n$	Norma euclidiana de $\mathbf{v}$.
$\lambda(A)$	$A \in \mathbb{R}^{n \times n}$	Conjunto de valores propios de A .
$A > 0$ ($A \geq 0$)	$A \in \mathbb{R}^{n \times n}$	A es simétrica positiva (semi-)definida.
v_a, v_b, v_c	V	Voltajes de fase aplicados al estator.
i_a, i_b, i_c	A	Corrientes de fase del estator.
e_a, e_b, e_c	V	Fuerzas contraelectromotrices de fase (BEMF).
u_α, u_β	V	Voltajes en el marco estacionario de Clarke.
i_α, i_β	A	Corrientes en el marco estacionario de Clarke.
e_α, e_β	V	BEMF en el marco $\alpha\beta$.
$\mathbf{i}_{\alpha\beta}$	$\in \mathbb{R}^2$	Vector de corriente $[i_\alpha, i_\beta]^T$.
$\mathbf{u}_{\alpha\beta}$	$\in \mathbb{R}^2$	Vector de voltaje $[u_\alpha, u_\beta]^T$.
$\mathbf{e}_{\alpha\beta}$	$\in \mathbb{R}^2$	Vector de BEMF $[e_\alpha, e_\beta]^T$.

Continúa en la siguiente página

Símbolo	Nota	Significado
$\mathbf{u}_j$	$j = 0, \dots, 7$	Vectores de voltaje admisibles del inversor trifásico.
R	Ω	Resistencia de fase del estator.
L	H	Inductancia síncrona equivalente de fase.
V_{DC}	V	Tensión del bus de corriente directa.
ω_m	rad/s	Velocidad mecánica del rotor.
ω_e	rad/s	Velocidad eléctrica del rotor, $\omega_e = p\omega_m$.
θ_m	rad	Posición mecánica del rotor.
θ_e	rad	Posición eléctrica del rotor, $\theta_e = p\theta_m$.
p	–	Número de pares de polos.
K_e	V·s/rad	Constante de fuerza contraelectromotriz.
K_t	N·m/A	Constante de par.
J	kg·m ²	Momento de inercia del rotor.
d	N·m·s	Coefficiente de fricción viscosa.
T_e	N·m	Par electromagnético desarrollado.
T_L	N·m	Par de carga.
$\mathbf{s}(\theta_e)$	$\in \mathbb{R}^2$	Función de forma normalizada de la BEMF en $\alpha\beta$.
T_s	s	Periodo de muestreo del controlador.
ρ	$\in \mathbb{N}$	Número de sub-intervalos en que se divide T_s en FCS-M2PC.
t_1, t_2, t_0	s	Tiempos de aplicación de los vectores activos y nulo.
$\mathbf{i}^*(k)$	A	Referencia de corriente en el instante k .
g	–	Función de costo del controlador predictivo.
$\mathbf{x}(\theta)$	$\in \mathbb{R}^{2H}$	Vector de regresores de Fourier truncados a H armónicos.
$\mathbf{w}$	$\in \mathbb{R}^{2H}$	Vector de pesos del ADALINE.
<i>Continúa en la siguiente página</i>		

Símbolo	Nota	Significado
H	$\in \mathbb{N}$	Número de armónicos retenidos en la expansión de Fourier.
μ	–	Paso de adaptación del algoritmo LMS.
$\epsilon(k)$	–	Error de estimación $s_{\text{obs}}(k) - \hat{s}(k)$ en el paso k .
$(\hat{\cdot})$	–	Estimación de la cantidad indicada.

Cuadro 1: Notación

Introducción

1.1. Motivación

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

1.2. Estado del arte

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim.

Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetur adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

1.3. Contribución

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetur.

1.4. Estructura de la tesis

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

Preliminares

Este capítulo reúne el material que se usará a lo largo de la tesis. La intención no es ser exhaustivo, sino fijar la notación y enunciar los resultados que más adelante se aplican sin volver a explicarlos. Se cubre el modelo del motor BLDC, las transformaciones de marco de referencia que usaremos, el inversor trifásico, la familia de controladores predictivos que da pie al FCS-M2PC, y finalmente el ADALINE con base de Fourier, que será la herramienta de estimación adaptable de BEMF.

2.1. El motor BLDC y el origen del rizo de par

El motor BLDC (*brushless direct current*) tiene un rotor de imanes permanentes y tres devanados en el estator conectados en estrella. La conmutación, que en un motor de corriente directa convencional se realiza mecánicamente con escobillas, aquí se hace electrónicamente a través de un inversor. Esta diferencia le da al BLDC una eficiencia más alta, menor mantenimiento y mejor relación par-velocidad, razones por las que ha desplazado a los motores de corriente directa con escobillas en aplicaciones como vehículos eléctricos y robótica (Coronado-Andrade and Alvarez-Icaza, 2025; Krishnan, 2009).

Bajo la hipótesis de fases balanceadas y campo magnético uniformemente distribuido en el entrehierro, la fuerza contraelectromotriz (BEMF) inducida en cada devanado adopta una forma trapezoidal. Esta es la idealización que sostiene el control por conmutación de seis pasos y, en general, todo análisis introductorio del BLDC (Krause et al., 2013). Sin embargo, ningún motor real tiene un campo perfectamente uniforme. Las ranuras del estator, las tolerancias de fabricación de los imanes y la geometría del rotor introducen armónicos en la BEMF: principalmente el quinto, séptimo y onceavo, múltiplos impares no triples de la frecuencia eléctrica fundamental. La consecuencia es que la BEMF deja de ser trapezoidal pura y la forma de onda real cae en algún lugar entre el trapecio y la senoide, dependiendo del motor en cuestión (Shao, 2003).

A esta desviación se suman dos efectos adicionales. El primero es el par de detención o *cogging torque*, una componente del par que depende únicamente de la posición del rotor y aparece por la interacción entre los imanes y los dientes del estator. El segundo es el *dead-time* del inversor, un retardo introducido en el disparo de los transistores para evitar cortocircuitos, que distorsiona el voltaje efectivamente aplicado al motor. Ambos efectos son periódicos en la posición eléctrica θ_e y, junto con los armónicos de BEMF, son las fuentes principales del rizo de par.

El rizo de par, definido como la oscilación periódica del par electromagnético en torno a su valor medio, es indeseable porque genera vibraciones, ruido acústico y pérdida de precisión en aplicaciones de seguimiento. En sistemas de tracción eléctrica también se traduce en pérdida de eficiencia y desgaste prematuro de la transmisión. Reducirlo es el problema que motiva esta tesis y se planteará formalmente en el capítulo 3.

2.2. Modelo eléctrico-mecánico en el marco abc

Asumiendo fases balanceadas y despreciando las pérdidas en el hierro y los efectos de saturación magnética, el motor BLDC se modela en el marco *abc* como (Coronado-Andrade et al., 2023; Krause et al., 2013)

$$L \frac{d\mathbf{i}_{abc}}{dt} = \mathbf{u}_{abc} - R \mathbf{i}_{abc} - \mathbf{e}_{abc}(\theta_e), \quad (2.1a)$$

$$J \frac{d\omega_m}{dt} = T_e - d\omega_m - T_L, \quad (2.1b)$$

$$\frac{d\theta_m}{dt} = \omega_m, \quad (2.1c)$$

donde $\mathbf{i}_{abc} = [i_a, i_b, i_c]^\top$ son las corrientes de fase, $\mathbf{u}_{abc}$ los voltajes aplicados, $\mathbf{e}_{abc}(\theta_e)$ las BEMFs, R y L son la resistencia y la inductancia síncrona de fase, J es el momento de inercia, d el coeficiente de fricción viscosa, T_L el par de carga y ω_m, θ_m la velocidad y posición mecánicas del rotor.

Las BEMFs se escriben como el producto de la constante K_e , la velocidad mecánica y una función de forma normalizada que depende de la posición eléctrica:

$$\mathbf{e}_{abc}(\theta_e) = K_e \omega_m \mathbf{s}_{abc}(\theta_e), \quad (2.2)$$

con $\mathbf{s}_{abc} = [s_a(\theta_e), s_b(\theta_e - 2\pi/3), s_c(\theta_e + 2\pi/3)]^\top$. La función s_a codifica la forma de onda del motor (trapezoidal, senoidal o algo intermedio) y las otras dos son sus versiones desfasadas $\pm 2\pi/3$. El par electromagnético se obtiene del balance de potencia,

$$T_e = K_t \mathbf{s}_{abc}^\top(\theta_e) \mathbf{i}_{abc}, \quad (2.3)$$

donde K_t es la constante de par. En unidades SI consistentes $K_t = K_e$, aunque por convención se

mantiene la distinción.

La relación entre la posición eléctrica y la mecánica es $\theta_e = p \theta_m$, con p el número de pares de polos del motor, y análogamente $\omega_e = p \omega_m$. La hipótesis de fases balanceadas implica $i_a + i_b + i_c = 0$, lo que reduce el sistema eléctrico a dos grados de libertad y motiva pasar a un marco de referencia bifásico.

2.3. Transformada de Clarke

La transformada de Clarke proyecta las tres corrientes de fase sobre un sistema cartesiano ortogonal $\alpha\beta$ fijo al estator:

$$\begin{bmatrix} i_\alpha \\ i_\beta \end{bmatrix} = \frac{2}{3} \begin{bmatrix} 1 & -\frac{1}{2} & -\frac{1}{2} \\ 0 & \frac{\sqrt{3}}{2} & -\frac{\sqrt{3}}{2} \end{bmatrix} \begin{bmatrix} i_a \\ i_b \\ i_c \end{bmatrix}. \quad (2.4)$$

La misma transformación se aplica a los voltajes y a las BEMFs. El factor $2/3$ preserva la amplitud de las señales de fase; existe la convención alterna $\sqrt{2/3}$, que preserva potencia, pero a lo largo de la tesis se usará la primera.

Bajo (2.4), el modelo eléctrico del motor queda

$$L \frac{d}{dt} \begin{bmatrix} i_\alpha \\ i_\beta \end{bmatrix} = \begin{bmatrix} u_\alpha \\ u_\beta \end{bmatrix} - R \begin{bmatrix} i_\alpha \\ i_\beta \end{bmatrix} - \begin{bmatrix} e_\alpha(\theta_e) \\ e_\beta(\theta_e) \end{bmatrix}, \quad (2.5)$$

y la BEMF en este marco se expresa como $\mathbf{e}_{\alpha\beta}(\theta_e) = K_e \omega_m \mathbf{s}(\theta_e)$, con $\mathbf{s}(\theta_e) \in \mathbb{R}^2$ la función de forma en $\alpha\beta$. Para un motor senoidal ideal $\mathbf{s}(\theta_e) = [\sin \theta_e, -\cos \theta_e]^\top$; para un motor real con armónicos, $\mathbf{s}(\theta_e)$ se desvía de esta expresión.

En el contexto de máquinas senoidales (PMSM) es habitual ir un paso más allá y aplicar la transformada de Park, que pasa de $\alpha\beta$ a un marco dq síncrono con el rotor. La ventaja de Park es que las cantidades en régimen permanente quedan constantes, lo que facilita el diseño de controladores lineales. La desventaja, y la razón por la que en esta tesis se trabajará en $\alpha\beta$, es que Park supone implícitamente una BEMF senoidal pura: si el motor contiene armónicos, estos no desaparecen en dq , sino que aparecen como rizados a múltiplos de la frecuencia eléctrica. Para un BLDC con forma de onda no senoidal, el marco $\alpha\beta$ es más natural porque no impone esa hipótesis y deja la información armónica intacta en $\mathbf{s}(\theta_e)$ (Rodríguez and Cortés, 2012).

2.4. El inversor trifásico y sus vectores admisibles

El motor se alimenta a través de un inversor fuente de voltaje (VSI) de dos niveles, compuesto por tres ramas con dos transistores cada una. Cada rama tiene dos estados útiles —superior cerrado o inferior cerrado—, por lo que el inversor presenta $2^3 = 8$ combinaciones admisibles de conmutación. Etiquetando el estado de cada rama como $S_a, S_b, S_c \in \{0, 1\}$, los ocho vectores resultantes se denotan $\mathbf{u}_0, \mathbf{u}_1, \dots, \mathbf{u}_7$ y se listan en el cuadro 2.1.

Cuadro 2.1: Vectores de voltaje admisibles del VSI de dos niveles en el marco $\alpha\beta$. V_{DC} es la tensión del bus.

$\mathbf{u}_j$	S_a	S_b	S_c	(u_α, u_β)
$\mathbf{u}_0$	0	0	0	$(0, 0)$
$\mathbf{u}_1$	1	0	0	$(\frac{2}{3}V_{DC}, 0)$
$\mathbf{u}_2$	1	1	0	$(\frac{1}{3}V_{DC}, \frac{\sqrt{3}}{3}V_{DC})$
$\mathbf{u}_3$	0	1	0	$(-\frac{1}{3}V_{DC}, \frac{\sqrt{3}}{3}V_{DC})$
$\mathbf{u}_4$	0	1	1	$(-\frac{2}{3}V_{DC}, 0)$
$\mathbf{u}_5$	0	0	1	$(-\frac{1}{3}V_{DC}, -\frac{\sqrt{3}}{3}V_{DC})$
$\mathbf{u}_6$	1	0	1	$(\frac{1}{3}V_{DC}, -\frac{\sqrt{3}}{3}V_{DC})$
$\mathbf{u}_7$	1	1	1	$(0, 0)$

Seis de los vectores son activos ($\mathbf{u}_1$ a $\mathbf{u}_6$) y forman un hexágono regular de radio $\frac{2}{3}V_{DC}$ en el plano $\alpha\beta$. Los dos restantes, $\mathbf{u}_0$ y $\mathbf{u}_7$, son nulos y corresponden a tener todos los transistores superiores o todos los inferiores cerrados; ambos aplican voltaje cero al motor. Cualquier estrategia de control que se ejecute sobre un VSI —PWM senoidal, modulación vectorial, FCS-MPC— es, en última instancia, una regla que decide en cada instante cuál de estos ocho vectores aplicar y por cuánto tiempo.

2.5. Control predictivo basado en modelo

El control predictivo basado en modelo (MPC) usa un modelo dinámico del sistema para predecir su comportamiento futuro y elegir la acción que minimiza una función de costo predefinida (Rodríguez and Cortés, 2012; Kouro et al., 2009). En su versión continua y clásica, MPC resuelve en cada paso un problema de optimización sobre una trayectoria continua de la entrada y entrega al actuador la señal óptima a través de un modulador (PWM, modulación vectorial, etc.). Esta arquitectura es la que se usa, por ejemplo, en plantas químicas o robots, donde la entrada puede tomar cualquier valor real dentro de un rango.

Cuando el actuador es un convertidor de potencia, este planteamiento se simplifica de manera radical. El inversor solo puede tomar un número finito de configuraciones, y en lugar de optimizar sobre un continuo y luego modular, conviene optimizar directamente sobre el conjunto discreto de

vectores admisibles. Esta es la idea del *Finite Control Set Model Predictive Control* (FCS-MPC), introducido en su forma moderna por [Kouro et al. \(2009\)](#). En cada periodo de muestreo T_s , FCS-MPC predice la corriente que produciría cada uno de los ocho vectores del cuadro 2.1 si se aplicara durante todo el periodo, evalúa una función de costo g —típicamente el error cuadrático respecto a la referencia— y aplica el vector que minimiza g . No hay modulador.

La simplicidad de FCS-MPC tiene un costo: aplicar un único vector durante todo T_s produce un rizo de corriente notable a menos que T_s sea muy pequeño, lo que exige hardware de muy alta velocidad y motores con inductancia suficiente para integrar el escalón ([Coronado-Andrade and Alvarez-Icaza, 2025](#)). Para mantener la simplicidad del FCS pero reducir el rizo, [Coronado-Andrade and Alvarez-Icaza \(2025\)](#) proponen el FCS-M2PC, que divide T_s en ρ sub-intervalos y aplica combinaciones de dos vectores activos adyacentes más un vector nulo, escogiendo no solo qué vectores aplicar sino qué fracción de T_s asignarle a cada uno. La derivación completa se difiere al capítulo 4; aquí basta con la intuición: el M2PC combina lo mejor del FCS-MPC (conjunto finito de estados, sin modulador) con lo mejor de la modulación clásica (suavizado dentro del periodo de muestreo). El resultado reportado por los autores es una reducción del 75 al 80 por ciento en el RMSE del seguimiento de corriente respecto al FCS-MPC clásico, bajo el mismo T_s .

2.6. ADALINE y el algoritmo LMS

El *Adaptive Linear Neuron* (ADALINE) es la estructura de aprendizaje supervisado más simple posible. Introducido por [Widrow and Hoff \(1960\)](#), consiste en un único combinador lineal: dada una entrada $\mathbf{x}(k) \in \mathbb{R}^n$ y un vector de pesos $\mathbf{w}(k) \in \mathbb{R}^n$, su salida es

$$\hat{y}(k) = \mathbf{w}^\top(k) \mathbf{x}(k). \quad (2.6)$$

No hay capas ocultas, no hay funciones de activación; el ADALINE es, formalmente, una regresión lineal con actualización en línea. Lo que lo hace interesante es la regla con la que se ajustan sus pesos.

Dado un valor deseado $y(k)$, se define el error de estimación $\epsilon(k) = y(k) - \hat{y}(k)$ y se actualizan los pesos mediante el algoritmo *Least Mean Squares* (LMS):

$$\mathbf{w}(k+1) = \mathbf{w}(k) + \mu \epsilon(k) \mathbf{x}(k), \quad (2.7)$$

donde $\mu > 0$ es el paso de adaptación. La ecuación (2.7) es la versión estocástica de un descenso por gradiente sobre el error cuadrático instantáneo: en cada paso, los pesos se mueven en la dirección que más rápido reduce $\epsilon^2(k)$.

Las propiedades del LMS están bien documentadas en la literatura de procesamiento adaptable de señales ([Widrow and Stearns, 1985](#); [Haykin, 2014](#)) y se enuncian aquí sin demostración. El

algoritmo converge en media a la solución de mínimos cuadrados $\mathbf{w}^* = \mathbf{R}^{-1}\mathbf{p}$ —con $\mathbf{R} = \mathbb{E}[\mathbf{x}\mathbf{x}^\top]$ y $\mathbf{p} = \mathbb{E}[y\mathbf{x}]$ — siempre que $0 < \mu < 2/\lambda_{\max}(\mathbf{R})$. La velocidad de convergencia está controlada por la dispersión de los valores propios de $\mathbf{R}$: si el cociente $\lambda_{\max}/\lambda_{\min}$ es grande, los modos lentos dominan y la convergencia se prolonga. En régimen permanente, el LMS no converge a un valor fijo sino a una vecindad de $\mathbf{w}^*$ cuyo tamaño es proporcional a μ , fenómeno conocido como *misadjustment*. Esto impone el compromiso clásico entre velocidad y precisión: μ grande converge rápido pero deja más residuo; μ pequeño es preciso pero lento.

El costo computacional del LMS es lineal en la dimensión del vector de pesos: una actualización requiere $\mathcal{O}(n)$ multiplicaciones y sumas. Esta ligereza es la razón por la que el LMS y sus variantes siguen siendo los algoritmos de filtrado adaptable más utilizados en aplicaciones de tiempo real.

2.7. Series de Fourier truncadas como base para señales periódicas

Una función real $f(\theta)$ definida en $[0, 2\pi)$ y periódica de periodo 2π admite la representación en serie de Fourier

$$f(\theta) = \frac{a_0}{2} + \sum_{n=1}^{\infty} [a_n \cos(n\theta) + b_n \sin(n\theta)], \quad (2.8)$$

donde a_n y b_n son los coeficientes de Fourier. Las funciones $\{\cos(n\theta), \sin(n\theta)\}_{n \geq 1}$ forman una base ortogonal de $L^2([0, 2\pi))$, lo que garantiza que la serie converge en norma cuadrática a f siempre que f sea de cuadrado integrable.

En la práctica, las señales de interés tienen energía espectral concentrada en los primeros armónicos. Una BEMF de motor real, por ejemplo, está dominada por el primer armónico y contiene contribuciones decrecientes del tercero, quinto, séptimo y onceavo. Truncar (2.8) a un orden H finito,

$$f_H(\theta) = \frac{a_0}{2} + \sum_{n=1}^H [a_n \cos(n\theta) + b_n \sin(n\theta)], \quad (2.9)$$

introduce un error de aproximación cuya norma cuadrática es exactamente la energía contenida en los armónicos superiores a H . Si esa energía es despreciable, la aproximación es prácticamente exacta.

La estructura de (2.9) se presta naturalmente a ser implementada como un ADALINE. Definiendo el regresor

$$\mathbf{x}(\theta) = [\cos \theta, \sin \theta, \cos 2\theta, \sin 2\theta, \dots, \cos H\theta, \sin H\theta]^\top \in \mathbb{R}^{2H} \quad (2.10)$$

y el vector de pesos $\mathbf{w} = [a_1, b_1, a_2, b_2, \dots, a_H, b_H]^\top$, la salida del ADALINE $\mathbf{w}^\top \mathbf{x}(\theta)$ reproduce (2.9) sin la componente de continua, que para la BEMF es nula por la simetría del motor. Esta correspondencia tiene dos consecuencias que se explotarán en el capítulo 4.

La primera es la interpretabilidad: cada peso del ADALINE coincide con un coeficiente de Fourier de la BEMF, así que su magnitud indica directamente la amplitud del armónico correspondiente. La segunda es el buen condicionamiento del LMS: bajo la base $\{\cos n\theta, \sin n\theta\}$, la matriz de autocorrelación $\mathbf{R} = \mathbb{E}[\mathbf{x}\mathbf{x}^T]$ es múltiplo de la identidad cuando θ se distribuye uniformemente, lo que elimina la dispersión de valores propios y permite que todos los modos converjan al mismo ritmo (Haykin, 2014).

Modelo y planteamiento del problema

En el capítulo anterior se introdujeron los elementos del motor BLDC, el inversor y los marcos de referencia que se usarán a lo largo de la tesis. Toca ahora reescribir el modelo en una forma adecuada para el control, derivar la referencia de corriente que sostiene un par constante, identificar dónde aparece el rizo de par cuando el modelo difiere de la planta y enunciar formalmente el problema que esta tesis se propone resolver.

3.1. Modelo del motor en el marco $\alpha\beta$

Bajo las hipótesis ya enunciadas en el capítulo 2 —fases balanceadas, sin saturación, sin pérdidas en el hierro—, y aplicando la transformada de Clarke al modelo trifásico, el motor BLDC queda descrito por

$$L \frac{d\mathbf{i}_{\alpha\beta}}{dt} = \mathbf{u}_{\alpha\beta} - R \mathbf{i}_{\alpha\beta} - \mathbf{e}_{\alpha\beta}(\theta_e), \quad (3.1a)$$

$$J \frac{d\omega_m}{dt} = T_e - d\omega_m - T_L, \quad (3.1b)$$

$$\frac{d\theta_e}{dt} = p\omega_m, \quad (3.1c)$$

con las definiciones de la sección 2.2. La BEMF se factoriza como

$$\mathbf{e}_{\alpha\beta}(\theta_e) = K_e \omega_m \mathbf{s}(\theta_e), \quad (3.2)$$

donde $\mathbf{s}(\theta_e) \in \mathbb{R}^2$ es la función de forma de la BEMF en el marco $\alpha\beta$, normalizada de tal manera que K_e recoja la amplitud y $\mathbf{s}$ solo la forma de onda. El par electromagnético desarrollado por el motor toma la expresión correspondiente:

$$T_e = K_t \mathbf{s}^\top(\theta_e) \mathbf{i}_{\alpha\beta}. \quad (3.3)$$

La ecuación (3.3) es la pieza central del análisis que sigue. El par es el producto interno entre la forma de onda de la BEMF y el vector de corriente, escalado por K_t . Si $\mathbf{s}(\theta_e)$ no es senoidal pura, la corriente que mantiene T_e constante tampoco lo será, y la calidad del par dependerá directamente del conocimiento que el controlador tenga de $\mathbf{s}$.

Para los propósitos de simulación y de implementación digital, el modelo continuo se discretiza con el método de Euler. Con un periodo de muestreo T_s pequeño respecto a la dinámica eléctrica del motor, la dinámica de corriente (3.1a) se aproxima como

$$\mathbf{i}_{\alpha\beta}(k+1) = \mathbf{i}_{\alpha\beta}(k) + \frac{T_s}{L} [\mathbf{u}_{\alpha\beta}(k) - R\mathbf{i}_{\alpha\beta}(k) - \mathbf{e}_{\alpha\beta}(k)], \quad (3.4)$$

que es la base sobre la que opera el FCS-MPC y su variante M2PC, como se mostrará en el capítulo 4.

3.2. Generación de la referencia de corriente

El objetivo de control de par es mantener el par electromagnético T_e tan cerca como sea posible de un valor de referencia T_{ref} , que se produce típicamente por un lazo externo de velocidad. La pregunta inmediata es: ¿qué corriente $\mathbf{i}_{\alpha\beta}^*$ debe entregar el lazo interno para que $T_e = T_{\text{ref}}$?

Por (3.3), cualquier corriente que satisfaga $K_t \mathbf{s}^T \mathbf{i}^* = T_{\text{ref}}$ produce el par deseado. Como la ecuación tiene una sola restricción y la corriente vive en $\mathbb{R}^2$, el conjunto de soluciones es una recta. Para seleccionar un único punto de esa recta es necesario un criterio adicional. El criterio estándar en la literatura de control de máquinas (Le-Huy et al., 1986; Krishnan, 2009) es minimizar las pérdidas en el cobre, que son proporcionales a $\|\mathbf{i}\|^2$. El problema queda entonces como

$$\min_{\mathbf{i} \in \mathbb{R}^2} \|\mathbf{i}\|^2 \quad \text{sujeto a} \quad K_t \mathbf{s}^T(\theta_e) \mathbf{i} = T_{\text{ref}}. \quad (3.5)$$

La solución se obtiene formando el Lagrangiano $\mathcal{L} = \|\mathbf{i}\|^2 + \lambda(T_{\text{ref}} - K_t \mathbf{s}^T \mathbf{i})$, derivando respecto a $\mathbf{i}$ y sustituyendo en la restricción:

$$\mathbf{i}_{\alpha\beta}^*(\theta_e) = \frac{T_{\text{ref}}}{K_t \|\mathbf{s}(\theta_e)\|^2} \mathbf{s}(\theta_e). \quad (3.6)$$

Esta es la referencia de corriente óptima en el sentido de pérdidas mínimas, originalmente propuesta por Le-Huy et al. (1986). La interpretación geométrica es directa: la corriente debe ser paralela a $\mathbf{s}(\theta_e)$ en todo instante, con una amplitud inversamente proporcional al cuadrado de la norma de $\mathbf{s}$.

La fórmula (3.6) tiene dos consecuencias relevantes para esta tesis. Primero, si $\mathbf{s}(\theta_e)$ es senoidal pura, entonces $\|\mathbf{s}\|^2$ es constante y la referencia es una senoide perfecta; este es el caso del PMSM y el motivo por el que la transformación de Park funciona tan bien en esa familia. Segundo, si $\mathbf{s}(\theta_e)$

es trapezoidal o contiene armónicos, entonces $\|\mathbf{s}\|^2$ varía con θ_e , y la referencia óptima contiene esas mismas variaciones: la corriente que mantiene un par constante es, ella misma, una función no senoidal de la posición.

3.3. El rizo de par como *model mismatch*

En la práctica, el controlador no conoce $\mathbf{s}(\theta_e)$ exactamente: lo que tiene es un modelo $\hat{\mathbf{s}}(\theta_e)$, típicamente derivado de una hipótesis simplificadora —trapezoidal ideal, senoidal ideal o, en el mejor de los casos, una tabla de búsqueda obtenida del fabricante—. Llamemos $\tilde{\mathbf{s}}(\theta_e) = \mathbf{s}(\theta_e) - \hat{\mathbf{s}}(\theta_e)$ al error del modelo de BEMF. Este error se propaga al rizo de par por dos vías distintas, ambas inherentes a la arquitectura del FCS-M2PC.

La primera vía es la generación de referencia. Usando $\hat{\mathbf{s}}$ en lugar de $\mathbf{s}$ en (3.6), el controlador genera

$$\hat{\mathbf{i}}_{\alpha\beta}^*(\theta_e) = \frac{T_{\text{ref}}}{K_t \|\hat{\mathbf{s}}(\theta_e)\|^2} \hat{\mathbf{s}}(\theta_e), \quad (3.7)$$

y el par realmente producido, suponiendo seguimiento perfecto de corriente, es

$$T_e = K_t \mathbf{s}^T(\theta_e) \hat{\mathbf{i}}_{\alpha\beta}^*(\theta_e) = T_{\text{ref}} \frac{\mathbf{s}^T(\theta_e) \hat{\mathbf{s}}(\theta_e)}{\|\hat{\mathbf{s}}(\theta_e)\|^2}. \quad (3.8)$$

El cociente $\mathbf{s}^T \hat{\mathbf{s}} / \|\hat{\mathbf{s}}\|^2$ es igual a uno solamente cuando $\mathbf{s} = \hat{\mathbf{s}}$. En cuanto $\tilde{\mathbf{s}} \neq 0$, ese cociente varía con θ_e y aparece directamente como rizo de par en T_e , aun cuando el lazo interno de corriente sea perfecto.

La segunda vía es la predicción del controlador predictivo. El FCS-M2PC, como se verá en (3.4) y en el capítulo 4, predice la corriente al final del periodo de muestreo usando una estimación de la BEMF; al usar $\hat{\mathbf{e}}_{\alpha\beta} = K_e \omega_m \hat{\mathbf{s}}(\theta_e)$ en lugar de la BEMF real, la corriente predicha está sesgada por $T_s K_e \omega_m \tilde{\mathbf{s}}/L$. El vector de voltaje escogido para minimizar la función de costo es, en consecuencia, subóptimo, y el error de seguimiento de corriente se transfiere al par a través de (3.3).

Las dos vías se refuerzan. El error de modelo en $\mathbf{s}$ corrompe la referencia que el lazo interno trata de seguir, y simultáneamente corrompe la predicción que el lazo interno usa para decidir qué hacer. Esta observación es la motivación central de la tesis: si se pudiera reemplazar $\hat{\mathbf{s}}$ por una estimación que se acerque a $\mathbf{s}$ a partir de datos del motor en operación, las dos vías de propagación del rizo se atacarían simultáneamente con un mismo mecanismo.

3.4. Planteamiento del problema

Las consideraciones anteriores permiten enunciar formalmente el problema que se aborda en esta tesis.

Problema 1. Considérese el motor BLDC modelado por (3.1)–(3.3), alimentado por un VSI de dos niveles que produce los ocho vectores de voltaje admisibles del cuadro 2.1. Supóngase que la posición eléctrica θ_e y las corrientes $\mathbf{i}_{\alpha\beta}$ son medibles, que los parámetros eléctricos R , L y K_e son conocidos con una incertidumbre acotada, y que la función de forma de la BEMF $\mathbf{s}(\theta_e)$ es periódica de periodo 2π con energía espectral concentrada en los primeros H armónicos, pero su forma exacta es *desconocida a priori*.

Diseñar un esquema de control en tiempo discreto que, a partir de una referencia de par T_{ref} generada por un lazo externo de velocidad, seleccione en cada periodo de muestreo T_s una combinación de vectores admisibles del inversor tal que el par electromagnético resultante $T_e(t)$ siga a T_{ref} minimizando el rizo

$$\Delta T_e = \max_{t \in [t_0, t_0 + \Delta]} T_e(t) - \min_{t \in [t_0, t_0 + \Delta]} T_e(t),$$

medido en régimen permanente, donde Δ corresponde a un número entero de periodos eléctricos.

El requisito de que $\mathbf{s}(\theta_e)$ sea desconocida a priori distingue este planteamiento de la mayoría de los esquemas FCS-MPC reportados, que asumen una forma de onda fija (trapezoidal o senoidal) en su modelo interno. La restricción a una clase de funciones periódicas con espectro finito —asunción razonable para cualquier motor real, donde la energía cae rápido por encima del onceavo armónico— es la que abre la puerta a estimar $\mathbf{s}$ con un número pequeño de parámetros.

3.5. Hipótesis

La hipótesis sobre la que se construye esta tesis es la siguiente. Si la función de forma de la BEMF $\mathbf{s}(\theta_e)$ se estima en línea con un modelo lineal en parámetros, parsimonioso y bien condicionado para su actualización por descenso de gradiente, y esa estimación se inyecta simultáneamente en la generación de la referencia de corriente y en el modelo de predicción del FCS-M2PC, entonces el rizo de par residual se reducirá de manera significativa respecto a esquemas que emplean modelos fijos de BEMF, sin requerir datos previos del motor ni aumentar la carga computacional a niveles incompatibles con una implementación en un microcontrolador de gama media.

Tres elementos sostienen esta hipótesis y se justifican a lo largo del capítulo 4. Primero, la base de Fourier truncada en H armónicos representa cualquier BEMF de motor real con error despreciable usando $2H$ parámetros, lo que la convierte en un modelo lineal de baja dimensión. Segundo, el

algoritmo LMS sobre esa base es óptimamente condicionado, ya que la matriz de autocorrelación es múltiplo de la identidad bajo posición uniformemente distribuida, y converge sin sufrir dispersión de modos. Tercero, la corrección actúa en los dos puntos donde el error de BEMF se traduce en rizo de par, de modo que la mejora se acumula.

3.6. Objetivos

Objetivo 1. Diseñar, analizar y validar en simulación un esquema de control predictivo de corriente FCS-M2PC con estimación adaptable en línea de la función de forma de la BEMF basada en un ADALINE con regresores de Fourier, capaz de reducir el rizo de par en motores BLDC con BEMF no senoidal sin requerir caracterización previa del motor.

Los objetivos específicos que estructuran este trabajo son:

- I) Formular el FCS-M2PC propuesto por [Coronado-Andrade and Alvarez-Icaza \(2025\)](#) en una forma que admita una BEMF estimada como parámetro de su modelo interno, sin perder las garantías de tiempo finito de aplicación dentro de un periodo de muestreo.
- II) Diseñar el ADALINE con base de Fourier para la representación de la BEMF, fijar la regla de actualización LMS y analizar sus propiedades de convergencia bajo posición uniformemente distribuida.
- III) Construir un observador discreto que recupere $\mathbf{s}(\theta_e)$ a partir de mediciones de corriente y voltaje en lazo cerrado, proporcionando la señal de aprendizaje al ADALINE en ausencia de un sensor de BEMF.
- IV) Integrar las tres piezas anteriores en una arquitectura única y comparar su desempeño contra esquemas FCS-M2PC con modelos fijos de BEMF (trapezoidal, senoidal y aprendido offline con redes neuronales profundas), usando un caso de estudio numérico.
- V) Caracterizar el rizo residual y discutir las fuentes que el esquema propuesto no puede atacar por construcción, identificando direcciones de trabajo futuro.

Control FCS-M2PC con estimación adaptable de la BEMF

El capítulo anterior dejó planteado el problema: el rizo de par nace del error entre la forma de onda real de la BEMF $\mathbf{s}(\theta_e)$ y el modelo $\hat{\mathbf{s}}(\theta_e)$ que el controlador usa, error que se propaga al par por dos vías a la vez. Toca ahora construir la solución. Primero se deriva el FCS-M2PC en la forma que admite una BEMF estimada como parámetro de su modelo interno. Después se diseña el ADALINE con base de Fourier que produce esa estimación, su entrenamiento offline y su versión adaptable en línea. Se argumenta por qué este modelo lineal es preferible a una red neuronal profunda. Finalmente se construye el observador que alimenta al ADALINE en lazo cerrado y se integran las piezas en una sola arquitectura.

4.1. Derivación del FCS-M2PC

El FCS-MPC clásico, descrito en la sección 2.5, aplica un único vector de voltaje durante todo el periodo de muestreo T_s . Esa decisión binaria —un vector, todo el periodo— es la que produce el rizo de corriente que se busca evitar. El FCS-M2PC de Coronado-Andrade and Alvarez-Icaza (2025) parte de la misma estructura de conjunto finito, pero reparte T_s entre dos vectores activos adyacentes y un vector nulo, decidiendo además qué fracción del periodo asignar a cada uno. El resultado conserva la ausencia de modulador externo del FCS y, a la vez, suaviza la trayectoria de corriente dentro del periodo.

4.1.1. Conjunto reducido de vectores admisibles

En lugar de evaluar los ocho vectores del cuadro 2.1 en cada periodo, el M2PC restringe la búsqueda a los dos vectores activos adyacentes al sector donde se encuentra el rotor más el vector nulo. El plano $\alpha\beta$ se divide en seis sectores de $\pi/3$ centrados en los vectores activos, y la posición

eléctrica θ_e determina cuál de ellos está vigente:

$$\mathcal{U}(\theta_e) = \begin{cases} \{\mathbf{u}_0, \mathbf{u}_2, \mathbf{u}_3\} & -\frac{\pi}{6} \leq \theta_e < \frac{\pi}{6}, \\ \{\mathbf{u}_0, \mathbf{u}_3, \mathbf{u}_4\} & \frac{\pi}{6} \leq \theta_e < \frac{3\pi}{6}, \\ \{\mathbf{u}_0, \mathbf{u}_4, \mathbf{u}_5\} & \frac{3\pi}{6} \leq \theta_e < \frac{5\pi}{6}, \\ \{\mathbf{u}_0, \mathbf{u}_5, \mathbf{u}_6\} & \frac{5\pi}{6} \leq \theta_e < \frac{7\pi}{6}, \\ \{\mathbf{u}_0, \mathbf{u}_6, \mathbf{u}_1\} & \frac{7\pi}{6} \leq \theta_e < \frac{9\pi}{6}, \\ \{\mathbf{u}_0, \mathbf{u}_1, \mathbf{u}_2\} & \frac{9\pi}{6} \leq \theta_e < \frac{11\pi}{6}. \end{cases} \quad (4.1)$$

La elección de los dos vectores adyacentes sigue el mismo criterio que la modulación vectorial: son los que mejor sintetizan la tensión deseada en ese sector. Reducir el conjunto a tres elementos baja el número de conmutaciones y, sobre todo, el número de veces que el algoritmo se ejecuta por periodo, lo que es determinante para que el cálculo quepa dentro de T_s en hardware real.




Figura 4.1: Sectores del plano $\alpha\beta$ y conjunto reducido de vectores admisibles por sector. El sector vigente (sombreado) determina los dos vectores activos adyacentes que, junto con el nulo, forman $\mathcal{U}(\theta_e)$.

4.1.2. Reparto del periodo y modelo de predicción

Denótese por $\mathbf{u}_a$ y $\mathbf{u}_b$ los dos vectores activos del sector vigente, y sean T_a , T_b y T_0 los tiempos durante los cuales se aplican $\mathbf{u}_a$, $\mathbf{u}_b$ y el vector nulo, respectivamente. Por construcción

$$T_a + T_b + T_0 = T_s. \quad (4.2)$$

Integrando la dinámica discreta (3.4) sobre el periodo, con cada vector aplicado durante su fracción de tiempo, la corriente predicha al final de T_s resulta

$$i_\alpha(k+1) = i_\alpha(k) + \frac{1}{L}(T_a u_{a\alpha}(k) + T_b u_{b\alpha}(k)) - \frac{T_s}{L}(e_\alpha(k) + R i_\alpha(k)), \quad (4.3a)$$

$$i_\beta(k+1) = i_\beta(k) + \frac{1}{L}(T_a u_{a\beta}(k) + T_b u_{b\beta}(k)) - \frac{T_s}{L}(e_\beta(k) + R i_\beta(k)). \quad (4.3b)$$

El vector nulo no aparece en (4.3) porque aplica tensión cero; su único efecto es completar el periodo según (4.2) y dejar tiempo para medir las corrientes. La BEMF entra a través de $\mathbf{e}_{\alpha\beta}(k) = K_e \omega_m \mathbf{s}(\theta_e(k))$, y es precisamente aquí donde el modelo de forma $\hat{\mathbf{s}}$ se inserta en la predicción: cualquier error en $\hat{\mathbf{s}}$ sesga $i_{\alpha\beta}(k+1)$ y, con ello, la decisión del controlador.

La figura 4.2 ilustra la idea sobre una trayectoria de corriente: dentro de un mismo periodo, la combinación de dos vectores activos y el nulo permite acercarse a la referencia con un escalón mucho menor que el del FCS clásico.




Figura 4.2: Operación del FCS-M2PC: el reparto de T_s entre dos vectores activos ($\mathbf{u}_a$, $\mathbf{u}_b$) y el nulo ($\mathbf{u}_0$) acerca la corriente a la referencia con un escalón mucho menor que el del FCS clásico, que aplica un solo vector durante todo el periodo.

4.1.3. Combinaciones, función de costo y selección

El M2PC no resuelve los tiempos T_a , T_b , T_0 por optimización continua. En su lugar, divide T_s en ρ sub-intervalos iguales de duración T_s/ρ y prueba todas las maneras de repartir esos ρ trozos entre los tres vectores admisibles. El número de repartos es el de combinaciones con repetición de $n = 3$ elementos en ρ ranuras,

$$C^R(n, \rho) = \frac{(n + \rho - 1)!}{\rho! (n - 1)!}, \quad (4.4)$$

que para $n = 3$ y $\rho = 4$ da quince combinaciones. Cada combinación fija una terna (T_a, T_b, T_0) múltiplo de T_s/ρ , y por tanto una corriente predicha distinta según (4.3).

Para cada una de las $C^R(n, \rho)$ combinaciones se evalúa la misma función de costo del FCS-MPC: el error cuadrático entre la referencia y la corriente predicha,

$$g = (i_\alpha^*(k+1) - i_\alpha(k+1))^2 + (i_\beta^*(k+1) - i_\beta(k+1))^2, \quad (4.5)$$

donde $\mathbf{i}_{\alpha\beta}^*(k+1)$ es la referencia de corriente generada según (3.6). La combinación que minimiza g se modula y se aplica al inversor en el siguiente periodo. El procedimiento completo se resume en el algoritmo 1.

Algoritmo 1 FCS-M2PC para un periodo de muestreo

Entradas: $\mathbf{i}(k)$, $\theta_e(k)$, ω_m , $\hat{\mathbf{s}}(\theta_e)$, T_{ref}

- 1: Determinar el sector y el conjunto $\mathcal{U}(\theta_e)$ según (4.1)
 - 2: Calcular la referencia $\mathbf{i}_{\alpha\beta}^*(k+1)$ con (3.6) usando $\hat{\mathbf{s}}$
 - 3: $g_{\text{op}} \leftarrow \infty$
 - 4: **for** $j \leftarrow 1$ a $C^R(3, \rho)$ **do**
 - 5: Tomar la terna $(T_a, T_b, T_0)_j$ de la combinación j
 - 6: Predecir $\mathbf{i}_{\alpha\beta}(k+1)$ con (4.3) usando $\hat{\mathbf{e}} = K_e \omega_m \hat{\mathbf{s}}$
 - 7: Evaluar g_j con (4.5)
 - 8: **if** $g_j < g_{\text{op}}$ **then**
 - 9: $g_{\text{op}} \leftarrow g_j$; $j_{\text{op}} \leftarrow j$
 - 10: **end if**
 - 11: **end for**
 - 12: **devolver** modular la combinación j_{op} sobre el inversor
-

Dos parámetros gobiernan el compromiso del M2PC. El número de sub-intervalos ρ mejora el seguimiento al permitir repartos más finos, pero (4.4) crece con ρ y con ello el tiempo de cómputo por periodo; existe un ρ máximo que el hardware sostiene antes de que el cálculo desborde T_s . El propio modelo de BEMF $\hat{\mathbf{s}}$ aparece en dos lugares del algoritmo —en la línea 2, al generar la referencia, y en la línea 6, al predecir—, lo que confirma lo anticipado en la sección 3.3: corregir $\hat{\mathbf{s}}$ ataca las dos vías de propagación del rizo con un mismo mecanismo.

4.2. ADALINE con base de Fourier para la BEMF

El bloque que falta es el que produce $\hat{\mathbf{s}}(\theta_e)$. La sección 2.7 mostró que una función periódica de espectro concentrado se representa con pocos armónicos, y que esa representación coincide con la salida de un ADALINE alimentado por un regresor de Fourier. Esa correspondencia es la que se explota aquí.

Cada componente de la función de forma $\mathbf{s}(\theta_e) = [s_\alpha(\theta_e), s_\beta(\theta_e)]^\top$ se modela como una serie de Fourier truncada a H armónicos. Con el regresor definido en (2.10),

$$\mathbf{x}(\theta_e) = [\cos \theta_e, \sin \theta_e, \dots, \cos H\theta_e, \sin H\theta_e]^\top \in \mathbb{R}^{2H},$$

la forma estimada se escribe como un producto matriz-vector,

$$\hat{\mathbf{s}}(\theta_e) = \mathbf{W}^T \mathbf{x}(\theta_e), \quad \mathbf{W} = [\mathbf{w}_\alpha \ \mathbf{w}_\beta] \in \mathbb{R}^{2H \times 2}, \quad (4.6)$$

donde cada columna de $\mathbf{W}$ recoge los coeficientes de Fourier de una componente de $\mathbf{s}$. La estructura es la de dos ADALINE que comparten el mismo regresor: uno estima s_α y otro s_β . La componente de continua se omite porque la simetría del motor la anula.




Figura 4.3: Estructura del ADALINE con regresor de Fourier para la estimación de $\mathbf{s}(\theta_e)$. La posición θ_e genera el regresor $\mathbf{x}(\theta_e)$; dos combinadores lineales con pesos $\mathbf{w}_\alpha$, $\mathbf{w}_\beta$ producen $\hat{s}_\alpha$, $\hat{s}_\beta$. No hay capas ocultas ni funciones de activación: la salida es lineal en los pesos.

Conviene distinguir desde ya dos modos de operar este estimador. En el modo *offline* los pesos se calculan una sola vez a partir de un conjunto de datos y luego quedan fijos; sirve de referencia y de inicialización. En el modo *online* los pesos se actualizan en cada periodo con la información que entrega el motor en operación; es el modo que da a la tesis su carácter adaptable. Las dos subsecciones siguientes tratan cada caso.

4.3. Entrenamiento offline por mínimos cuadrados

Supóngase que se dispone de un conjunto de N muestras $\{(\theta_i, \mathbf{s}_i)\}_{i=1}^N$ de la forma de onda, obtenidas de un ensayo de caracterización o de un modelo previo del motor. Apilando los regresores por filas en la matriz $\Phi \in \mathbb{R}^{N \times 2H}$, con $\Phi_{i,:} = \mathbf{x}^T(\theta_i)$, y las muestras en $\mathbf{S} \in \mathbb{R}^{N \times 2}$, el ajuste de los pesos es un problema de mínimos cuadrados lineal:

$$\mathbf{W}^* = \arg \min_{\mathbf{W}} \|\Phi \mathbf{W} - \mathbf{S}\|_F^2, \quad (4.7)$$

cuya solución es la pseudoinversa

$$\mathbf{W}^* = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{S}. \quad (4.8)$$

La estructura de la base de Fourier vuelve este cálculo particularmente benigno. Si las muestras están equiespaciadas en $[0, 2\pi)$, la ortogonalidad de $\{\cos n\theta, \sin n\theta\}$ hace que $\Phi^T \Phi$ sea un múltiplo de la identidad, y (4.8) se reduce a evaluar las integrales de Fourier de forma discreta. No hay mal condicionamiento que invertir ni regularización que ajustar: los pesos óptimos son, literalmente, los coeficientes de Fourier de la forma de onda muestreada.

El entrenamiento offline cumple dos funciones en esta tesis. Da una cota inferior del rizo alcanzable cuando se conoce la BEMF con precisión, contra la cual se mide el modo online. Y proporciona una inicialización razonable de $\mathbf{W}$ para el arranque del LMS, de modo que la adaptación parta de una forma de onda plausible y no de cero.

4.4. Aprendizaje en línea con LMS

El modo online prescinde de la caracterización previa. Los pesos se ajustan en cada periodo con el error entre la forma de onda que el motor revela en operación y la que el ADALINE predice. Sea $\mathbf{s}_{\text{med}}(k)$ la muestra de forma de onda disponible en el instante k —su origen se detalla en la sección 4.6, ya que en operación no se mide $\mathbf{s}$ directamente sino que se reconstruye—. El error de estimación es

$$\boldsymbol{\epsilon}(k) = \mathbf{s}_{\text{med}}(k) - \mathbf{W}^T(k) \mathbf{x}(\theta_e(k)) \in \mathbb{R}^2, \quad (4.9)$$

y la actualización LMS, aplicada columna a columna como en (2.7), es

$$\mathbf{W}(k+1) = \mathbf{W}(k) + \mu \mathbf{x}(\theta_e(k)) \boldsymbol{\epsilon}^T(k). \quad (4.10)$$

Cada paso mueve los pesos en la dirección que más rápido reduce $\|\boldsymbol{\epsilon}\|^2$, sin más que un producto externo entre el regresor y el error.

La sección 2.6 enunció las propiedades del LMS en general; sobre la base de Fourier esas propiedades toman su mejor forma. La matriz de autocorrelación del regresor, bajo posición eléctrica uniformemente distribuida —hipótesis que se cumple en régimen permanente, donde el rotor barre todos los ángulos por igual—, es

$$\mathbf{R} = \mathbb{E}[\mathbf{x}(\theta_e) \mathbf{x}^T(\theta_e)] = \frac{1}{2} \mathbf{I}_{2H}. \quad (4.11)$$

Que $\mathbf{R}$ sea múltiplo de la identidad tiene una consecuencia fuerte: todos sus valores propios son iguales, la dispersión $\lambda_{\text{máx}}/\lambda_{\text{mín}}$ vale uno, y los $2H$ modos del LMS convergen exactamente al mismo ritmo. No hay modos lentos que retrasen la adaptación. La condición de estabilidad $0 < \mu < 2/\lambda_{\text{máx}}(\mathbf{R}) = 4$ se satisface con holgura para los pasos pequeños de interés. En régimen permanente

los pesos no se detienen en $\mathbf{W}^*$, sino que fluctúan en una vecindad de tamaño proporcional a μ (el *misadjustment* de la sección 2.6); esto fija el compromiso de diseño: μ grande para converger rápido tras un cambio, μ pequeño para dejar poco residuo una vez convergido.

El costo computacional es el del LMS: $\mathcal{O}(H)$ multiplicaciones y sumas por periodo para cada componente. Con H del orden de diez, son unas decenas de operaciones por periodo, despreciables frente al barrido de las $C^R(3, \rho)$ combinaciones del M2PC. La adaptación de la BEMF no es lo que limita la frecuencia de muestreo.

4.5. Por qué un ADALINE y no una red neuronal profunda

La estimación de la BEMF podría plantearse con una red neuronal profunda, y de hecho la literatura reciente lo hace (Ali et al., 2024). Esta tesis se decide por el ADALINE de forma deliberada, por tres razones estructurales que una red profunda no comparte.

La primera es la **convergencia garantizada**. El ADALINE es lineal en sus parámetros, así que el error cuadrático es una función convexa de los pesos con un único mínimo global. El LMS desciende sobre esa superficie sin riesgo de quedar atrapado en mínimos locales, y su convergencia en lazo cerrado se puede analizar con las herramientas estándar de filtrado adaptable. Una red profunda tiene una superficie de error no convexa, sin garantía de convergencia online y con un riesgo real de comprometer la estabilidad del lazo de control cuando se entrena en tiempo real.

La segunda es la **parsimonia**. La base de Fourier truncada representa cualquier BEMF de motor real con $2H$ parámetros —del orden de veinte a cuarenta—. En la fase de caracterización offline de este trabajo, un ADALINE de cuarenta pesos igualó el error de reconstrucción de una red profunda de unos veinticinco mil parámetros. El costo por actualización es lineal en el número de pesos, lo que lo hace compatible con la aritmética de un microcontrolador de gama media; una red profunda no cabe en ese presupuesto de cómputo dentro de un periodo de muestreo.

La tercera es la **interpretabilidad física**. Cada peso del ADALINE es un coeficiente de Fourier de la BEMF, así que su magnitud indica directamente la amplitud del armónico correspondiente. El vector de pesos es, en sí mismo, el espectro de la forma de onda del motor. Esto permite vigilar el estado del estimador, diagnosticar el contenido armónico del motor y, de cara al trabajo futuro con control repetitivo, diseñar el filtro a partir de los armónicos que el propio ADALINE revela. Una red profunda es una caja negra de la que no se extrae esa información.

4.6. Observador de BEMF en lazo cerrado

La actualización LMS (4.10) necesita la muestra $\mathbf{s}_{\text{med}}(k)$, pero en un motor en operación la forma de onda no se mide: no hay un sensor que entregue $\mathbf{s}(\theta_e)$. Lo que sí se mide son la posición eléctrica θ_e , las corrientes $\mathbf{i}_{\alpha\beta}$ y se conoce el voltaje aplicado $\mathbf{u}_{\alpha\beta}$. El observador reconstruye la BEMF a partir de esas señales y de ahí deriva la muestra que alimenta al ADALINE.

Despejar la BEMF directamente del modelo (2.5) exigiría derivar la corriente medida, operación que amplifica el ruido. En su lugar se usa un observador de corriente que estima la BEMF como una entrada desconocida. Sobre la dinámica discreta, el observador propaga una corriente estimada $\hat{\mathbf{i}}_{\alpha\beta}$ y corrige con el error de medición:

$$\hat{\mathbf{i}}_{\alpha\beta}(k+1) = \hat{\mathbf{i}}_{\alpha\beta}(k) + \frac{T_s}{L} [\mathbf{u}_{\alpha\beta}(k) - R\hat{\mathbf{i}}_{\alpha\beta}(k) - \hat{\mathbf{e}}_{\alpha\beta}(k)] + \mathbf{L}_o(\mathbf{i}_{\alpha\beta}(k) - \hat{\mathbf{i}}_{\alpha\beta}(k)), \quad (4.12)$$

con $\mathbf{L}_o$ la ganancia del observador. La BEMF estimada $\hat{\mathbf{e}}_{\alpha\beta}$ se obtiene integrando el error de corriente, de modo que el observador la trata como la perturbación que explica la discrepancia entre la corriente medida y la predicha por el modelo eléctrico. Una vez disponible $\hat{\mathbf{e}}_{\alpha\beta}(k)$, la muestra de forma de onda se recupera normalizando por la amplitud:

$$\mathbf{s}_{\text{med}}(k) = \frac{\hat{\mathbf{e}}_{\alpha\beta}(k)}{K_e \omega_m(k)}, \quad (4.13)$$

que es justamente la señal que entra en (4.9). La división por ω_m advierte de una limitación que se discutirá en el capítulo de validación: a velocidad muy baja la BEMF se hace pequeña frente al ruido y la muestra pierde calidad, lo que justifica el esquema híbrido encoder-observador que esta tesis adopta en lugar de un sensorless puro.




Figura 4.4: Observador discreto de BEMF que provee la señal de aprendizaje al ADALINE. La ganancia $\mathbf{L}_o$ corrige el modelo con el error de corriente $\mathbf{i} - \hat{\mathbf{i}}$; la BEMF estimada $\hat{\mathbf{e}}_{\alpha\beta}$ se normaliza por $K_e \omega_m$ para recuperar la muestra de forma de onda $\mathbf{s}_{\text{med}}$.

4.7. Arquitectura integrada

Las piezas anteriores se ensamblan en un solo lazo. Un controlador externo PI de velocidad genera la referencia de par T_{ref} a partir del error de velocidad. Con la BEMF estimada $\hat{s}$ del ADALINE, el bloque de referencia produce $i_{\alpha\beta}^*$ según (3.6). El FCS-M2PC toma esa referencia y, usando otra vez $\hat{s}$ en su predicción (4.3), elige y modula la combinación de vectores que aplica al inversor. El motor responde; se miden corriente y posición; el observador reconstruye $\hat{e}_{\alpha\beta}$ y de ahí s_{med} ; el LMS actualiza $\mathbf{W}$ y devuelve un $\hat{s}$ mejorado a los dos bloques que lo consumen. El lazo se cierra sobre sí mismo: cuanto mejor estima el ADALINE la forma de onda, mejor es la referencia y mejor la predicción, y a su vez una mejor operación entrega mejores muestras al ADALINE.




Figura 4.5: Arquitectura integrada del FCS-M2PC con estimación adaptable de BEMF. La estimación $\hat{s}$ del ADALINE (en naranja) se inyecta a la vez en la generación de la referencia y en la predicción del FCS-M2PC: los dos puntos donde el error de modelo de BEMF se convertía en rizo de par.

La figura 4.5 resume el aporte de este trabajo. La estimación de la BEMF no es un añadido lateral, sino que se inyecta en los dos puntos exactos donde el error de modelo se convertía en rizo de par, identificados en la sección 3.3. El capítulo siguiente pone a prueba esta arquitectura en simulación y la compara contra esquemas que usan modelos fijos de BEMF.

Caso de estudio y validación numérica

El capítulo anterior dejó la arquitectura completa: un FCS-M2PC cuya referencia y cuya predicción consumen la estimación de BEMF que un ADALINE actualiza en línea, alimentado por un observador. Este capítulo la pone a prueba en simulación. Primero se describe el caso de estudio y los seis modelos de BEMF que se comparan. Después se presenta el estudio comparativo en el escenario de supervisión ideal, donde el LMS aprende de la forma de onda verdadera de la planta, y se examina la convergencia del aprendizaje. Luego se repite el experimento en el escenario realista, con el observador de BEMF cerrando el lazo de aprendizaje sobre mediciones ruidosas y cuantizadas. La discusión final contrasta los resultados con la hipótesis de la sección 3.5.

5.1. Configuración del caso de estudio

El motor simulado es el Anaheim BLY-344S-240V-3000, el mismo caso de estudio de [Coronado-Andrade and Alvarez-Icaza \(2025\)](#), lo que permite ubicar los resultados en continuidad con ese trabajo. El cuadro 5.1 resume los parámetros del motor y del esquema de control. La planta se integra con el modelo discreto (3.4) a un periodo de muestreo $T_s = 30 \mu s$, el mismo que usa el controlador. La función de forma verdadera $s(\theta_e)$ de la planta es una tabla de búsqueda de alta resolución con perfil cuasi-trapezoidal y transiciones suaves, representativa de la BEMF de un BLDC real; el controlador nunca accede a esa tabla, salvo a través del modelo $\hat{s}$ que cada método define.

Con $\rho = 10$ sub-intervalos, la fórmula (4.4) da $C^R(3, 10) = 66$ combinaciones que el M2PC evalúa por periodo. El ADALINE trunca la serie de Fourier en $H = 10$ armónicos, de modo que $\mathbf{W} \in \mathbb{R}^{20 \times 2}$: cuarenta pesos en total. La actualización LMS se habilita solo cuando $|\omega_m| > 5$ rad/s, para no dividir por amplitudes de BEMF cercanas a cero durante el arranque.

El escenario de prueba es el mismo para todos los métodos. El motor parte del reposo hacia una referencia de velocidad $\omega^* = 80$ rad/s sostenida por el PI externo, con una carga inicial $T_L = 0,5$ N·m. En $t = 150$ ms la carga escalona a 1,5 N·m. La simulación cubre 300 ms, es decir, 10^4 periodos

Cuadro 5.1: Parámetros del motor y del esquema de control usados en la validación numérica.

Motor (Anaheim BLY-344S)		Control	
R	$1,2 \Omega$	T_s	$30 \mu s$
L	$2,05 \text{ mH}$	ρ	10 sub-intervalos
K_e	$0,40355 \text{ V}\cdot\text{s/rad}$	K_p, K_i (PI vel.)	0,5, 50
K_t	$0,65997 \text{ N}\cdot\text{m/A}$	Saturación PI	$\pm 5 \text{ N}\cdot\text{m}$
p	4 pares de polos	H	10 armónicos
J	$2,7948 \times 10^{-4} \text{ kg}\cdot\text{m}^2$	μ (LMS)	5×10^{-3}
d	$6,738 \times 10^{-4} \text{ N}\cdot\text{m}\cdot\text{s/rad}$	σ ruido de corriente	50 mA
V_{dc}	240 V	ADC	12 bits, $\pm 10 \text{ A}$

de muestreo. A 80 rad/s con cuatro pares de polos, la frecuencia eléctrica es de unos 51 Hz y el periodo eléctrico de 19,6 ms.

Los seis modelos de BEMF que se comparan son:

TRAP forma trapezoidal ideal fija, la hipótesis clásica para BLDC.

SIN fundamental puro, la hipótesis del PMSM.

LEARNED tabla aprendida offline por una red neuronal profunda de unos veinticinco mil parámetros, entrenada sobre datos de la forma verdadera.

ADALINE-OFF ADALINE con pesos óptimos calculados offline por (4.8) y congelados.

ADALINE-ON-T ADALINE en línea, inicializado con el ajuste de Fourier del trapecio ideal.

ADALINE-ON-S ADALINE en línea, inicializado solo con el fundamental.

Los primeros cuatro usan modelos fijos durante toda la simulación; los dos últimos ejecutan la actualización LMS (4.10) en cada periodo. LEARNED y ADALINE-OFF conocen la forma verdadera a través de su entrenamiento offline, así que actúan como cotas de referencia: indican el rizo alcanzable cuando la caracterización previa es perfecta.

Las métricas se calculan sobre el último 15 % de la simulación ($t \geq 255 \text{ ms}$), en régimen permanente y con la carga escalonada ya asentada. El rizo de par se reporta como $100 \sigma(T_e)/\bar{T}_e$; se acompaña del valor pico a pico T_e P-P, que corresponde directamente al ΔT_e del problema 1, del rizo de velocidad pico a pico y del RMSE de seguimiento de corriente en el eje α .

El aprendizaje en línea se evalúa en dos escenarios. En el primero, de *supervisión ideal*, la muestra $\mathbf{s}_{\text{med}}(k)$ que consume el LMS es la forma verdadera de la planta; este escenario aísla las propiedades del ADALINE de las imperfecciones de su señal de aprendizaje. En el segundo, *con observador*, la muestra proviene del observador de la sección 4.6 operando sobre corrientes contaminadas con ruido gaussiano de $\sigma = 50 \text{ mA}$ y cuantizadas por un ADC de 12 bits a fondo de

escala de ± 10 A, y llega con un periodo de retardo. Los cuatro métodos fijos no dependen de la señal de aprendizaje, así que sus resultados son idénticos en ambos escenarios.

5.2. Comparación con supervisión ideal

La figura 5.1 muestra la corrida completa. Los seis métodos alcanzan la referencia de velocidad en menos de 15 ms y absorben el escalón de carga con una caída breve que el PI recupera en unos 20 ms; en las variables lentas el comportamiento es indistinguible. Las diferencias viven en la escala fina del par, y ahí es donde las métricas de régimen permanente separan a los métodos.




Figura 5.1: Corrida completa de los seis métodos con supervisión ideal: velocidad, salida del PI, par electromagnético y magnitud de corriente. El escalón de carga de 0,5 a 1,5 N·m entra en $t = 150$ ms. En las variables lentas los métodos son indistinguibles; las diferencias aparecen en la escala fina del par y de la salida del PI, donde TRAP y SIN oscilan visiblemente.

El cuadro 5.2 concentra los resultados y la figura 5.2 los detalla sobre dos revoluciones eléctricas. Los cuatro métodos que conocen la forma de onda —LEARNED, ADALINE-OFF y los dos ADALINE en línea ya convergidos— terminan en un rizo de 1,87 a 1,90 %, empatados entre sí. Los dos modelos fijos idealizados quedan lejos: 6,06 % para TRAP y 6,43 % para SIN, con pulsaciones de

par cuya frecuencia dominante ronda el sexto armónico de la frecuencia eléctrica y que se transfieren a la velocidad como una oscilación de casi 0,5 rad/s pico a pico, un orden de magnitud por encima de la de los métodos adaptables.

Cuadro 5.2: Métricas de régimen permanente con supervisión ideal ($t \geq 255$ ms, carga de 1,5 N·m).

Método	Rizo [%]	T_e P-P [N·m]	ω P-P [rad/s]	RMSE i_α [A]
TRAP	6.06	0.3758	0.4960	0.1743
SIN	6.43	0.3860	0.5401	0.1181
LEARNED	1.89	0.1355	0.0495	0.0609
ADALINE-OFF	1.90	0.1318	0.0656	0.0601
ADALINE-ON-T	1.88	0.1283	0.0587	0.0604
ADALINE-ON-S	1.87	0.1418	0.0528	0.0609




Figura 5.2: Régimen permanente con supervisión ideal. Arriba: par y velocidad sobre dos revoluciones eléctricas; TRAP y SIN exhiben la pulsación periódica que los métodos con forma de onda aprendida no tienen. Abajo: rizo de par y rizo de velocidad pico a pico por método.

Tres lecturas salen de esta tabla. La primera es la magnitud de la mejora: el ADALINE en línea reduce el rizo de 6,06 a 1,88 % respecto al modelo trapezoidal, una reducción del 69 %, y el rizo de velocidad cae en proporción similar. La segunda es que el ADALINE de cuarenta pesos empata a la red profunda de veinticinco mil parámetros —1,88 contra 1,89 %—, que es el argumento de parsimonia de la sección 4.5 verificado en lazo cerrado. La tercera es que las versiones en línea empatan también a la offline, es decir, el LMS alcanzó en operación el mismo punto que la pseudoinversa calcula con todos los datos por adelantado, sin caracterización previa del motor.

Hay un resultado que merece atención aparte: SIN produce *más* rizo que TRAP (6,43 contra 6,06 %) a pesar de seguir mejor su referencia de corriente (0,118 contra 0,174 A de RMSE). No es una contradicción, es la firma de las dos vías de propagación de la sección 3.3. La referencia senoidal es fácil de seguir —es suave y el predictor senoidal comete poco error de seguimiento—, pero es la corriente equivocada: por (3.8), el par que produce hereda toda la variación del cociente $\mathbf{s}^\top \hat{\mathbf{s}} / \|\hat{\mathbf{s}}\|^2$. El modelo trapezoidal, con peor seguimiento, está más cerca de la forma verdadera y genera una referencia más correcta. El rizo de par no es una función monótona del error de seguimiento de corriente; depende de qué corriente se persigue. Por eso reducir el RMSE de corriente no basta como objetivo de diseño, y por eso la corrección debe actuar sobre $\hat{\mathbf{s}}$, no solo sobre el lazo de corriente.

5.3. Convergencia del aprendizaje en línea

La figura 5.3 sigue la trayectoria de los pesos de los dos ADALINE en línea hacia el óptimo offline $\mathbf{W}^*$, medida como error relativo en norma de Frobenius. La inicialización trapezoidal parte de un error del 60 % y la senoidal del 33 %; ambas cruzan el umbral del 5 % entre los 25 y los 35 ms de simulación —del orden de un periodo eléctrico y medio— y quedan por debajo del 1 % antes de los 80 ms. Las dos trayectorias descienden de forma monótona y sin estancamientos, que es lo que anticipaba el análisis de la sección 4.4: con $\mathbf{R} = \frac{1}{2}\mathbf{I}$, todos los modos del LMS convergen al mismo ritmo y no hay direcciones lentas en las que el error se rezague.




Figura 5.3: Convergencia del ADALINE en línea con supervisión ideal. Izquierda: error relativo de pesos $\|\mathbf{W} - \mathbf{W}^*\|_F / \|\mathbf{W}^*\|_F$ para las dos inicializaciones; ambas cruzan el 5 % en 25–35 ms. Derecha: rizo de par instantáneo (ventana móvil de una revolución eléctrica); tras la convergencia, los métodos en línea se asientan en el nivel de los métodos con caracterización previa. El pico en $t = 150$ ms lo produce el escalón de carga en todos los métodos por igual.

El panel derecho de la figura muestra el rizo instantáneo, calculado con una ventana móvil de

una revolución eléctrica. Tras el transitorio de arranque, los métodos en línea descienden al nivel de los que conocen la forma de onda y ahí permanecen. El pico alrededor de $t = 150$ ms no es una pérdida de convergencia: es el escalón de carga atravesando la ventana de cálculo, y afecta a los seis métodos por igual. Los pesos ya convergidos no se ven perturbados por el escalón, lo que confirma que el ADALINE estima una propiedad del motor —su forma de onda— y no un artefacto del punto de operación.

5.4. Aprendizaje con observador en lazo cerrado

El escenario anterior supone que el LMS recibe la forma de onda verdadera, cosa que ningún sistema real puede ofrecer. Aquí se sustituye esa señal por la muestra $\mathbf{s}_{\text{med}}$ que el observador de la sección 4.6 reconstruye según (4.13), a partir de corrientes con ruido de 50 mA y cuantización de 12 bits, y con un periodo de retardo. El cuadro 5.3 repite el estudio comparativo en estas condiciones.

Cuadro 5.3: Métricas de régimen permanente con el observador cerrando el lazo de aprendizaje. Los cuatro métodos fijos no consumen la señal del observador y repiten sus valores del cuadro 5.2.

Método	Rizo [%]	T_e P-P [N·m]	ω P-P [rad/s]	RMSE i_α [A]
TRAP	6.06	0.3758	0.4960	0.1743
SIN	6.43	0.3860	0.5401	0.1181
LEARNED	1.89	0.1355	0.0495	0.0609
ADALINE-OFF	1.90	0.1318	0.0656	0.0601
ADALINE-ON-T	2.36	0.2340	0.1222	0.0732
ADALINE-ON-S	2.48	0.2538	0.1022	0.0748

El costo de aprender de una señal reconstruida es visible pero moderado: el rizo de los métodos en línea sube de 1,88 a 2,36 % (inicialización trapezoidal) y de 1,87 a 2,48 % (senoidal). El ruido y la cuantización que atraviesan el observador se convierten en fluctuación permanente de los pesos —el *misadjustment* del LMS— y ese residuo separa al método en línea de su cota offline. Aun así, el resultado queda en 61 % de reducción de rizo respecto a TRAP y conserva intacto el orden de magnitud de mejora en el rizo de velocidad.

La convergencia, en cambio, sí paga un precio mayor (figura 5.4). El transitorio deja de ser monótono: durante el arranque la velocidad es baja, la BEMF es pequeña frente al ruido y la normalización por $K_e \omega_m$ en (4.13) amplifica el error del observador, así que las primeras muestras que recibe el LMS son de mala calidad y los pesos se agitan antes de encontrar la dirección correcta. La inicialización senoidal cruza el 5 % hacia los 50 ms; la trapezoidal, que arranca más lejos del óptimo y con más energía en los armónicos altos donde la señal reconstruida es menos confiable, tarda unos 120 ms. En ambos casos el error se asienta por debajo del 5 % y no diverge: el lazo de aprendizaje es robusto al ruido, solo es más lento a través de él.




Figura 5.4: Convergencia del ADALINE en línea con observador. La señal de aprendizaje ruidosa vuelve el transitorio errático y más lento que en la figura 5.3: la inicialización senoidal cruza el 5 % hacia los 50 ms y la trapezoidal hacia los 120 ms. En régimen permanente ambas fluctúan por debajo del 5 % sin divergir.

La figura 5.5 cierra el estudio con el seguimiento de corriente en $\alpha\beta$ durante los últimos 100 ms. Las referencias de TRAP y SIN son fáciles de seguir pero incorrectas, como se discutió en la sección 5.2. Las de los métodos con forma aprendida son visiblemente no senoidales —llevan impresos los armónicos de la forma verdadera, tal como exige (3.6)— y el controlador las sigue con un RMSE de 0,06 a 0,08 A. Es la imagen del mecanismo completo funcionando: el ADALINE aprende la forma, la referencia adopta esa forma, y el M2PC la ejecuta.

5.5. Discusión

Los resultados sostienen la hipótesis de la sección 3.5 en sus tres partes. El ADALINE con base de Fourier, actualizado por LMS e inyectado a la vez en la referencia y en la predicción, redujo el rizo de par un 69 % respecto al modelo trapezoidal en condiciones ideales y un 61 % cuando la señal de aprendizaje proviene de un observador sobre mediciones ruidosas y cuantizadas, sin datos previos del motor. La carga computacional añadida es marginal: las $\mathcal{O}(H)$ operaciones del LMS son decenas de multiplicaciones por periodo, frente al barrido de 66 combinaciones que el M2PC ya ejecuta.

Vale la pena precisar qué parte del rizo queda fuera del alcance del esquema. Los cuatro métodos que conocen la forma de onda comparten un piso de 1,9 % que el modelo de BEMF ya no explica: es el rizo propio del conjunto finito de acciones del M2PC, con su reparto de tiempos cuantizado en décimas de T_s , operando a una frecuencia de muestreo dada. Ese piso se ataca con más resolución en ρ o con T_s menor, no con un mejor modelo de BEMF. En el escenario con observador se suma el residuo de *misadjustment*, gobernado por el compromiso clásico del LMS: un μ menor

Grupo 1 — Seguimiento de Corriente $\alpha\beta$ (estado estable, 100 ms)




Figura 5.5: Seguimiento de corriente en $\alpha\beta$ durante los últimos 100 ms del escenario con observador (referencia en línea discontinua). Las referencias de los métodos con forma de onda aprendida son no senoidales: contienen los armónicos que (3.6) exige para sostener un par constante con la BEMF real del motor.

lo reduce a costa de una convergencia más lenta. Y quedan fuera del modelo de simulación las perturbaciones periódicas que no entran por la BEMF —el par de *cogging* y el efecto del tiempo muerto del inversor—, que en un banco real se superpondrían al resultado y demandan un mecanismo de compensación propio.

Dos limitaciones del estudio delimitan el alcance de las conclusiones. La primera es la zona de baja velocidad: la normalización por $K_e \omega_m$ degrada la muestra del observador cuando la BEMF es pequeña, y de hecho el LMS se inhabilita por debajo de 5 rad/s. El esquema aprende bien donde la BEMF es observable; cerca del reposo debe congelar los pesos y operar con lo aprendido, que es coherente con el planteamiento híbrido encoder-observador de esta tesis y no con un esquema *sensorless* puro. La segunda es que el observador operó con los parámetros eléctricos exactos de la planta; la sensibilidad del lazo de aprendizaje a errores en R y L no se caracterizó aquí y pertenece a la validación experimental.

Con la validación numérica cerrada, la arquitectura queda lista para el siguiente paso natural: su implementación en un microcontrolador y la contrastación en un banco físico, donde el costo computacional acotado y la interpretabilidad de los pesos —argumentadas en la sección 4.5— dejan de ser ventajas teóricas y se vuelven condiciones de trabajo.

Conclusiones

6.1. Conclusiones

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

6.2. Trabajo futuro

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim.

Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Bibliografía

- Ali, M. A., Sindhu, M. R., and Ramakrishna, D. S. P. (2024). Sensorless speed control of brushless DC motor using artificial neural network predicted back EMF. In *2024 IEEE International Conference on Power Electronics, Drives and Energy Systems (PEDES)*. IEEE. 21
- Coronado-Andrade, A. and Alvarez-Icaza, L. (2025). Finite control set model predictive control for current ripple reduction on BLDCs. *IEEE Open Journal of Power Electronics*. Manuscript draft. 3, 7, 14, 15, 24
- Coronado-Andrade, A., de la Guerra, A., and Alvarez-Icaza, L. (2023). Load torque observer for BLDC motors based on a HOSM differentiator. *Machines*. 4
- Haykin, S. (2014). *Adaptive Filter Theory*. Pearson, 5th edition. 7, 9
- Kouro, S., Cortés, P., Vargas, R., Ammann, U., and Rodríguez, J. (2009). Model predictive control — a simple and powerful method to control power converters. *IEEE Transactions on Industrial Electronics*, 56(6):1826–1838. 6, 7
- Krause, P. C., Wasynczuk, O., Sudhoff, S. D., and Pekarek, S. (2013). *Analysis of Electric Machinery and Drive Systems*. Wiley-IEEE Press, 3rd edition. 3, 4
- Krishnan, R. (2009). *Permanent Magnet Synchronous and Brushless DC Motor Drives*. CRC Press. 3, 11
- Le-Huy, H., Perret, R., and Feuillet, R. (1986). Minimization of torque ripple in brushless DC motor drives. *IEEE Transactions on Industry Applications*, IA-22(4):748–755. 11
- Rodríguez, J. and Cortés, P. (2012). *Predictive Control of Power Converters and Electrical Drives*. Wiley-IEEE Press. 5, 6
- Shao, J. (2003). *Direct Back EMF Detection Method for Sensorless Brushless DC (BLDC) Motor Drives*. M.Sc. thesis, Virginia Polytechnic Institute and State University. 3
- Widrow, B. and Hoff, M. E. (1960). Adaptive switching circuits. In *IRE WESCON Convention Record*, pages 96–104. 7

Widrow, B. and Stearns, S. D. (1985). *Adaptive Signal Processing*. Prentice-Hall, Englewood Cliffs, NJ. 7